

三种方法对比报告

我们用三种原理完全不同的方法,把同一批传感器信号各识别了一遍,看看结论是否一致,以及深度学习到底有没有帮助。

数据规模	2661 次敲击 · 26 个字母 · 36 份录制(全部可用,未丢弃任何一份)
验证方式	5 折交叉验证,每次敲击都恰好被测试一次
最好成绩	99.96%(手工特征 + 随机森林,错 1 次)
规则解码	99.92%(错 2 次,且完全不需要训练数据)
深度模型	99.74%(Transformer,错 7 次)
主要结论	三种方法结论一致,深度学习没有带来提升

一句话总结

识别准确率高,并不是因为算法特别聪明,而是因为传感器信号本身足够干净、点和划本来就分得开。三种互不相干的方法都得到几乎相同的结果,正好证明了这一点 —— 这比只报一个模型的高准确率更有说服力。

报告回答四个问题


1. 三种方法分别怎么做?(不懂算法也能看明白)
2. 它们的结果一致吗?
3. 为什么把波形直接丢给神经网络反而更容易出错?
4. 数据本身有没有问题?

我们做了什么

传感器记录下来的是一条「电阻随时间变化」的曲线。手指按一下,电阻就鼓起一个包;按得轻而短是「点」,按得重而久是「划」。把一串点划按摩尔斯码表翻译过来,就是一个字母。

要把曲线还原成字母,中间必须有一套判断规则。问题是:这套规则应该由人写出来,还是交给机器去学?这正是「要不要用机器学习」的争议所在。

所以我们没有二选一,而是把三种做法都实现了一遍,让它们在完全相同的数据、完全相同的划分上比较。只有这样,比出来的差异才真的是方法本身的差异。



为什么要比三种,而不是只做一种

如果只用一种方法得到很高的准确率,读者没法判断这个结果是传感器信号好,还是算法凑巧调得好。三种原理完全不同的方法同时给出接近的结果,才能说明可分性来自材料与器件本身。对材料类论文来说,这是更强的论据。

一个重要前提:公平

三种方法共用同一套信号前端——去噪、去漂移、找出每一次按压——只有「怎么判断」这一步不同。这样比出来的才是判断方式本身,而不是前处理的差别。

另外,训练和测试是按录制的时间顺序切分的,不是随机打乱。相邻两次敲击的传感器状态几乎一样,随机打乱会让成绩虚高——这一点在审稿时经常被追问。

三种方法分别是什么

① 规则解码 —— 像人一样看波形

把肉眼判断的经验直接写成规则:在同一个字母里,鼓包更高或按得更久的那个就是划,另一个就是点。如果整个字母的几次按压高矮差不多(比如 S 是三个点),就改看按压持续了多久。
特点:不需要任何训练数据,拿来就能用,而且每一步都能讲清楚为什么。

② 手工特征 + 机器学习 —— 人给尺子,机器学怎么切

先把每次按压量成几个数字:峰有多高、按了多久、离上一次多远。再把这些数字交给常见的机器学习模型(随机森林、SVM),让它自己找分界线。
特点:需要一些训练数据,但用的还是我们指定的物理量,因此能看出哪个量最重要。

③ Transformer —— 让机器自己找规律

Transformer 是目前最新的一类模型,它的机制正好是把序列里的各个元素互相比较。而我们的核心规律恰恰是:点和划要跟同一个字母里的邻居比,不能看绝对值。
特点:我们用规则显式写下来的东西,它是自己学出来的 —— 两条路殊途同归。

对照组:1D-CNN 直接吃原始波形 —— 不给任何物理量

这一路刻意不做任何物理处理:把波形拉伸成固定长度,直接喂给神经网络,也就是最常见的做法。用它来回答一个问题:那些物理量到底有没有用?
结果:它的表现最差,而且错得很有规律 —— 下一页专门讲这件事。


一眼看完

方法	要不要训练数据	能不能解释	本次错误
规则解码	不需要	每一步都能讲清楚	2
手工特征 + 机器学习	少量	能看出哪个量最重要	1
Transformer	较多	黑箱	7
1D-CNN(原始波形)	较多	黑箱	31

四种做法用的是同一批数据、同一套划分,成绩可以直接放在一起比较。

结果:三种方法结论一致

在全部 2661 次敲击上,六种做法(三种主方法,外加 SVM、BiLSTM 两个旁证和一个对照组)的准确率都在 98.8% 以上。差别不在准不准,而在错几次 —— 所以右图用错误次数来看,更清楚。



怎么读这两张图

左图六根柱子几乎一样高,说明所有方法都能把字母认出来;右图才看得出差别:规则解码错 2 次,加上机器学习错 1 次,Transformer 错 7 次,而完全不用物理量的 1D-CNN 错了 31 次。

三点结论

- ① 深度模型没有带来提升。它们和规则法看的是同样的输入,只是把一条本来就确定的规律重新学了一遍,还学得没那么准。
- ② 规则解码与随机森林只差 1 次。在 2661 次里,这属于统计上分不出高下,不能说机器学习更好。
- ③ 真正拉开差距的是有没有用物理量,而不是模型够不够深 —— 不用物理量的那一路,错误多了十几倍。



这对论文意味着什么

可以写成「我们用三种独立方法交叉验证,结果一致」。这是在证明器件性能,而不是在比拼算法 —— 审稿人更难挑毛病,同时机器学习相关的图表也一应俱全。

结果二

E 和 T:为什么直接把波形丢给神经网络会出错

字母 E 是一个点,字母 T 是一个划。它们都只有一次按压,鼓包的形状一模一样,唯一的区别是——按住的时间不同。





问题出在哪

神经网络要求输入长度固定,所以常规做法是把每段波形拉伸成同样长度。可是一旦拉伸,「按了多久」这个信息就被抹掉了(见右上图,两条线几乎重合)——而这恰恰是区分 E 和 T 的唯一线索。

结果是可以预料的


直接吃原始波形的 1D-CNN 一共错了 31 次,其中 14 次就是把 E 和 T 弄混,占 45%。而保留了按压时长的其它几种方法,在 E 和 T 上一次都没错。



上面两张图把每一次敲击画成一个点,相似的挨在一起,灰色是其余 24 个字母。左图只看波形形状,E(蓝)和 T(黄)混成一团;右图用上按压时长后,两者完全分开。

机器学习自己选出了我们用的那个物理量

随机森林在学习的时候,会顺便算出哪个测量值对判断最有用。这一步完全由数据决定,我们没有干预。结果如下:



读出来的信息

排在最前面的四项是:按压时长(中位)、平均峰高、第2次按压时长、第1次按压时长。其中三项都和按压持续多久有关(图中红色的条)。

这正是我们在规则里用来区分点和划的那个量。也就是说,机器学习独立地、完全从数据出发,得出了和我们相同的结论。


为什么这张图值得放进论文

它把「我们选的物理量是对的」从一句主观判断,变成了一个可验证的结果:不是我们猜对了,而是数据本身就这么说。对于强调材料与算法协同设计的论文,这是一条很自然的证据链。

顺带一提,峰高也排得很靠前——说明「按得重」和「按得久」这两个物理量都在起作用,和我们规则里的两条判据正好对应。

规则解码不需要训练数据

机器学习方法都要先喂一批标好答案的数据才能开始工作,规则解码不需要——它从第一次敲击起就能用。下图横轴是喂进去的训练样本数。



图里说了什么

红色虚线是规则解码,它在横轴 0 处就已经是 99.92%。BiLSTM 只喂 156 个样本时是 95.0%,要喂到 509 个左右才追上;完全不用物理量的 1D-CNN 即使喂满 1567 个,也只有 98.9%,始终没追上。


为什么这一点在实际中重要

换一块传感器、换一个人按,或者要增加数字和标点,机器学习方法都得重新采集、重新标注、重新训练。规则解码不用——它读的是物理量,换了场景直接就能跑。

还有一个能力上的差别

26 类分类模型只能对一个切好的片段给出一个字母。而规则解码可以直接读一整段连续消息——我们已经验证过 SOS、HELP、WATER、ESCAPE 这类词能整句读出。「用一片柔性传感器实时解码任意消息」,比「分成 26 个类」更有应用价值,也更适合作为论文的应用落点。

数据情况



总体情况很好

26 个字母共 2661 次敲击,36 份录制全部可用,没有任何一份需要丢弃。绝大多数字母都在 100 次左右。

有两件小事想跟你确认

① 字母 X 只有 79 次。从波形看你是一直在按的,应该是录制在 36 分钟时结束了(按当时的节奏,录满 100 次大约需要 45 分钟)。这不影响现在的结论,如果方便的话可以补录约 20 次。

② 有一份文件叫 D13+F58,里面顺序录了两个字母:前面约 1000 秒是 D,之后是 F。我们按这个分界拆开后得到 33 次 D 和 68 次 F,解码全部正确。只是文件名里的数字(13、58)和实际条数对不上,想问一下命名的含义。

另外修好了一个问题

文件 K-30 早先被我们当成坏文件。重新检查发现:传感器是在第 544 秒才接触不良(电阻从 9.9 千欧跳到 23 兆欧),而 30 次 K 全部发生在那之前,一次都没丢。程序现在会自动识别并跳过这种故障时段,所以这 30 次已经全部加了回来。

这个修正挺重要:原来的程序遇到探头脱开时不会报错,只会安静地「看不到信号」,很容易被当成数据本身有问题。现在不会了。

小结与可提供的材料

四条结论

- ① 三种原理完全不同的方法都达到 98.8%~100%,结论一致。这说明字母之间的可分性来自传感器与材料本身,不依赖某个特定模型。
- ② 深度学习没有带来提升。Transformer 和 BiLSTM 的错误次数反而是规则解码的 3~7 倍。
- ③ 真正起作用的是物理量,不是模型深度。不用物理量、直接把波形喂进 CNN,错误多了十几倍,而且近一半是 E 和 T 混淆。
- ④ 随机森林独立地选出了按压时长作为最重要的测量值,与我们规则里用的量一致。

已经准备好的材料

结果图,15 张

混淆矩阵、方法对比、特征重要性、学习曲线、训练曲线、PR 与 ROC 曲线、t-SNE(二维与三维)。图内文字为英文,可直接投稿。

Origin 数据,17 个 CSV

每张图都配一份对应数据,可以在 Origin 里按自己的风格重画。

波形数据

26 个字母各 15 条重复,已对齐到统一时间轴,可直接画叠加曲线图。

完整代码

可直接用在新数据上,换传感器或换采样率都不需要改;遇到接触不良会自动跳过。

如果要写进论文

建议把这组对比写成「多方法交叉验证」,落点放在器件性能而不是算法优劣,同时保留 Transformer 与 CNN 的完整结果——机器学习相关的章节和图表都是齐的。共 2661 次敲击的逐次结果也都在,需要哪种写法我可以再整理。